Media

Definición 1.3.1 *La* MEDIA ARITMÉTICA *de cierto conjunto de números se encuentra sumando los números y dividiendo después entre la cantidad de datos. En otras palabras, si* $x_1, \ldots, x_n$ *son números, entonces la media aritmética de este conjunto de números está dada por*

$$\textit{Media aritmética} = \frac{x_1 + \cdots + x_n}{n}$$

En estadística se habla de MEDIA ARITMÉTICA POBLACIONAL*, y se simboliza por* μ*, cuando el conjunto de datos corresponden a los de la población; y de* MEDIA ARITMÉTICA MUESTRAL*, y se simboliza por* $\overline{x}$*, cuando se tienen en cuentan los datos de una muestra.*

Ejemplo 1.3.2 *Supongamos que tenemos la muestra siguiente de edades en año de principiantes de una universidad: 18, 18, 18, 18, 19, 19, 19, 20, 20, 21. Entonces, la media aritmética de estos datos es:*

$$\overline{x} = \frac{18 + 18 + 18 + 18 + 19 + 19 + 19 + 20 + 20 + 21}{10} = 19 \quad \blacktriangleleft$$

Generalmente, para calcular la media de un conjunto de datos es más cómodo utilizar la llamada *media aritmética ponderada*, la cual es un caso especial de la media aritmética. Esta se puede utilizar cuando se tienen varias observaciones con un mismo valor, lo que puede ocurrir si se han organizado los datos en una tabla de frecuencias.

Definición 1.3.3 *Dada la siguiente tabla de frecuencias no agrupadas:*

Dato	x_1	x_2	$\ldots$	x_k
Frecuencia	f_1	f_2	$\ldots$	f_k

en donde f_i *es la frecuencia del dato* x_i*. Si* n *es igual al total de datos, entonces, la* MEDIA ARITMÉTICA PONDERADA *o, simplemente,* MEDIA ARTIMÉTICA*, de los datos* $x_1, \ldots, x_k$ *se define como*

$$\textit{Media aritmética} = \frac{x_1 f_1 + \cdots + x_k f_k}{n}$$

Copyright © 2014. Universidad del Norte. All rights reserved

Llinás Solano, H. (2014). Introducción a la estadística con aplicaciones en ciencias sociales: (ed.). Universidad del Norte. https://elibro.net/es/ereader/ucuauhtemoc/70062?page=19

Ejemplo 1.3.4 *Para hallar la media aritmética de los datos del ejemplo* 1.2.1*, aplicaremos la definición* 1.3.3 *de la siguiente manera:*

$$\overline{x} = \frac{(3)(2)+(4)(1)+(5)(2)+(6)(3)+(7)(4)}{2+1+2+3+4} = 5,5 \quad \blacktriangleleft$$

Desventaja de la media

La media tiene una seria desventaja: se ve afectada por los valores extremos de una distribución. Como depende del valor de cada medida, los valores extremos pueden llevarla a representar defectuosamente los datos.

Mediana

Definición 1.3.5 *Para datos medidos en al menos una escala de intervalo, la* MEDIANA *es el puntaje medio* ***ordenado****.*

Para determinar la mediana de n datos, hay que realizar los siguientes pasos:

- Ordene los datos de menor a mayor con ayuda de un diagrama de tallo y hojas ordenado.
- El valor de la mediana dependerá del hecho de que n sea par o impar:
  - Si n es impar, entonces la mediana será el dato en el centro, es decir, la mediana es el dato que se encuentra en el lugar $\frac{n+1}{2}$;
  - si n es par, entonces la mediana es la media de los dos datos que ocupan posiciones centrales, es decir, la mediana es el promedio de las datos que se encuentran en los lugares $\frac{n}{2}$ y $\frac{n}{2}+1$.

  Nótese que, por ejemplo, $\frac{n+1}{2}$ no representa uno de los datos, sino el número de valores que deben contarse para llegar a la mediana.

Ejemplo 1.3.6 *El conjunto de números 3, 4, 4, 5, 6, 8, 8, 8 y 10 tiene mediana 6, puesto que ya los datos están ordenados, el número de datos es 9 (impar) y, en este caso, el 6 está ubicado en el centro (en el cuarto lugar).* ◀

Ejemplo 1.3.7 *El conjunto de números 5, 5, 7, 9, 11, 12, 15 y 18 tiene mediana* $\frac{1}{2}(9+11) = 10$*, puesto que ya los datos están ordenados, el número de datos es 8 (par), el 9 y el 11 son los dos datos que ocupan posiciones centrales y 10 es el promedio de estos dos datos.* ◀

Copyright © 2014. Universidad del Norte. All rights reserved

Llinás Solano, H. (2014). Introducción a la estadística con aplicaciones en ciencias sociales: (ed.). Universidad del Norte. https://elibro.net/es/ereader/ucuauhtemoc/70062?page=19

Ejemplo 1.3.8 *A continuación calcularemos las mediana para los datos organizados en la tabla de frecuencias* 1.4.

Tabla 1.4: Tabla de frecuencia acumulada para los datos del ejemplo 1.3.8

Dato	Frecuencia	Frecuencia acumulada
0	10	10
1	10	20
2	8	28
3	4	32
4	8	40

Como los datos se presentan en una tabla de frecuencias no agrupadas, para calcular la mediana es conveniente determinar las frecuencias acumuladas de los datos. Estas ya se encuentran en la tabla 1.4. *Como el total de datos es* $n = 40$ *(par), entonces la mediana es el promedio de las medidas que están en las posiciones* $\frac{n}{2} = 20$ *y* $\frac{n}{2} + 1 = 21$. *Para encontrar la mediana recomendamos contar los datos en dirección de la medida menor a la mayor. En la tabla es fácil ver que el dato en lugar 20 es 1 y que el dato en la posición 21 es 2. Por tanto, la mediana es:*

$$\textit{Mediana} = \frac{\textit{dato en la posición 20} + \textit{dato en la posición 21}}{2} = \frac{1+2}{2} = 1,5 \quad \blacktriangleleft$$

Ventajas y desventajas de la mediana

Una ventaja consiste en que la mediana no se ve afectada por valores extremos de la distribución. Su desventaja reside en que no es fácilmente determinable en forma manual si el conjunto de datos es grande, puesto que las medidas deben ordenarse primero y ponerse en orden numérico de menor a mayor.

Moda

Definición 1.3.9 *La* MODA, *si se da, es el dato con mayor frecuencia.*

Ejemplo 1.3.10 *El conjunto 2, 2, 5, 7, 9, 9, 9, 11 tiene moda 9 porque este valor es el dato con mayor frecuencia.* ◀

Copyright © 2014. Universidad del Norte. All rights reserved

Llinás Solano, H. (2014). Introducción a la estadística con aplicaciones en ciencias sociales: (ed.). Universidad del Norte. https://elibro.net/es/ereader/ucuauhtemoc/70062?page=19

Ventajas y desventajas de la moda

- Tiene dos ventajas: Para ciertas muestras pequeñas, se le determina fácilmente y, en general, no se ve afectada por los valores extremos de un conjunto de datos ordenados. Cuando se analizan datos categóricos, la moda es el único dato de tendencia central que puede utilizarse.

  Además, la moda puede usarse como una medida de tendencia central para datos numéricos empleados en sentido categórico.

  Una moda para datos en una tabla de frecuencia se encuentra localizando el valor de frecuencia máxima, si no todas las frecuencias son iguales. El dato que corresponde al valor de frecuencia máxima se toma como la moda.

  Ejemplo 1.3.11 *Para los datos proporcionados en el ejemplo* 1.2.3*, el refresco más popular es el A (es decir, la moda es el refresco A), puesto que es el que más se compra.* ◄

- La moda tiene varias desventajas como medida de tendencia central: una de ellas consiste en que para un cierto conjunto de datos no puede haber moda.

  Esta situación surge cuando todos los datos tienen la misma frecuencia. Otra desventaja reside en que la moda puede existir pero no ser única.

  Ejemplo 1.3.12 *(a) El conjunto 3, 3, 5, 5, 7 y 7 no tiene moda.*

  (b) El conjunto 3, 3, 5, 5, 5, 7, 7, 7, y 9 tiene dos modas: el 5 y el 7. ◄

1.3.2 Medidas de dispersión o de variabilidad

Los datos que se presentan en la tabla 1.5 muestran los salarios anuales de siete supervisores de ventas de una empresa y los de siete de otra empresa.

Observemos que ambos conjuntos de datos tienen la misma media (33.500 dólares) y la misma mediana (33.800 dólares).

Copyright © 2014. Universidad del Norte. All rights reserved

Llinás Solano, H. (2014). Introducción a la estadística con aplicaciones en ciencias sociales: (ed.). Universidad del Norte. https://elibro.net/es/ereader/ucuauhtemoc/70062?page=19

Tabla 1.5: Salarios anuales (en dólares) de la plantilla de supervisores de ventas de dos empresa

Empresa 1	34.500	30.700	32.900	36.000	34.100	33.800	32.500
Empresa 2	34.000	27.500	31.600	39.700	35.300	33.800	31.700

Por tanto, si nos limitásemos a fijarnos en las medidas de centralización, no tendríamos base alguna para distinguir entre la distribución de los salarios en las dos empresas.



(a) En la primera empresa



(b) En la segunda empresa

Figura 1.6: Dispersión de los salarios anuales de los empleados de dos empresas (compárese con los datos de la tabla 1.5)

Sin embargo, estas dos distribuciones son muy diferentes, como podemos apreciar en la figura 1.6. Evidentemente que los datos del segundo conjunto están mucho más dispersos que los del primero.

Una medida de centralización casi nunca es suficiente por sí sola para analizar adecuadamente las características de un conjunto de datos. Por lo general, necesitaremos, además, una medida de la *dispersión* o *variación* de los datos.

Entre éstas se encuentran el rango o recorrido, el rango intercuartil, la varianza, la desviación estándar (o típica) y el coeficiente de variación. Sólo estudiaremos las tres últimas. Para el resto se puede consultar la sección 1.3.3 de Llinás [14].

Copyright © 2014. Universidad del Norte. All rights reserved

Llinás Solano, H. (2014). Introducción a la estadística con aplicaciones en ciencias sociales: (ed.). Universidad del Norte. https://elibro.net/es/ereader/ucuauhtemoc/70062?page=19

Varianza y desviación estándar (o típica)

Definición 1.3.13 *La* VARIANZA DE UNA MUESTRA *con valores* $x_1, \ldots, x_n$ *se denota por* s^2 *y se define por*

$$s^2 = \frac{(x_1 - \overline{x})^2 + (x_2 - \overline{x})^2 + \cdots + (x_n - \overline{x})^2}{n-1}$$

La DESVIACIÓN ESTÁNDAR *(o* TÍPICA*)* MUESTRAL *de un conjunto de datos, denotada por* s*, se define como la raíz cuadrada de la varianza muestral de los datos. Es decir,* $s = \sqrt{\textit{Varianza muestral}}$*. Un forma equivalente para calcular la varianza muestral es:*

$$s^2 = \frac{(x_1^2 + x_2^2 + \cdots + x_n^2) - n\overline{x}^2}{n-1}$$

Ejemplo 1.3.14 *Si los datos 62, 80, 83, 72 y 73 constituyen una muestra, entonces* $\overline{x} = 74$*. Por lo tanto, la varianza muestral está dada por*

$$s^2 = \frac{(62-74)^2 + (80-74)^2 + (83-74)^2 + (72-74)^2 + (73-74)^2}{5-1} = \frac{266}{4} = 66,5$$

y la desviación muestral por $s = \sqrt{66,5} = 8,15$*.* ◀

Ventajas y desventajas de la varianza y la desviación estándar

Si la varianza se usa por sí misma como medida descriptiva de la dispersión, es difícil interpretarla, porque las unidades de la varianza son el cuadrado de las unidades de medida; en otras palabras, la desviación estándar se mide con las mismas unidades que las de los datos originales. Por esta razón, la desviación estándar se compara con más facilidad con el promedio y otros estadísticos que tienen las mismas unidades que los datos originales.

La varianza y la desviación estándar tienen una limitación seria: pueden verse afectadas en presencia de valores extremos, pues ambas dependen de la media, que se modifica por las medidas extremas.

Copyright © 2014. Universidad del Norte. All rights reserved

Llinás Solano, H. (2014). Introducción a la estadística con aplicaciones en ciencias sociales: (ed.). Universidad del Norte. https://elibro.net/es/ereader/ucuauhtemoc/70062?page=19

Cuando en un conjunto de datos están presentes valores extremos y requerimos una medida resistente a ellos, debemos utilizar el rango intercuartil (véase la sección 1.4).

Varianza y desviación típica para datos en tablas de frecuencia

A menudo tendremos ocasión de encontrar la varianza y la desviación estándar para datos desplegados en una tabla de frecuencia.

Definición 1.3.15 *La* VARIANZA MUESTRAL (PONDERADA) *de un conjunto de datos* $x_1, \ldots, x_n$ *con frecuencias* $f_1, \ldots, f_n$ *se calculan mediante las siguiente fórmula (*n *es el total de datos):*

$$s^2 = \frac{f_1(x_1 - \overline{x})^2 + \cdots + f_n(x_n - \overline{x})^2}{n \ - \ 1} \quad o \quad s^2 \ = \ \frac{(f_1 x_1^2 + \cdots + f_n x_n^2) \ - \ n\overline{x}^2}{n \ - \ 1}$$

Ejemplo 1.3.16 *En el ejemplo* 1.3.4 *encontramos que la media de los datos del ejemplo* 1.2.1 *es* $\overline{x} = 5,5$*. Por consiguiente, la varianza muestral será*

$$\begin{aligned} s^2 &= \frac{2 \cdot (3 - 5,5)^2 \ + \ 1 \cdot (4 - 5,5)^2 \ + \ 2 \cdot (5 - 5,5)^2 \ + \ 3 \cdot (6 - 5,5)^2 \ + \ 4 \cdot (7 - 5,5)^2}{(2 + 1 + 2 + 3 + 4) \ - \ 1} \\ &= 2,27273 \end{aligned}$$

y de esta forma la desvación es $s = \sqrt{2,27273} = 1,50756$*.* ◄

Aplicaciones de la desviación estándar poblacional

Hasta ahora hemos visto que la varianza y la desviación estándar son muy útiles para comparar la dispersión de dos poblaciones. Pero también podemos interpretar la desviación de una única población. Concretamente, puede usarse esta cantidad para estimar el porcentaje de valores de la población que se encontrarán a menos de una distancia específica de la media. Para construir tales estimaciones se utilizan dos reglas: la *regla de Tchebychev* (válida para cualquier población) y la *empírica*. Si se quiere profundizar en ello, el lector puede consultar la página 52 del texto de Llinás [14].

Copyright © 2014. Universidad del Norte. All rights reserved

Llinás Solano, H. (2014). Introducción a la estadística con aplicaciones en ciencias sociales: (ed.). Universidad del Norte. https://elibro.net/es/ereader/ucuauhtemoc/70062?page=19

El coeficiente de variación de Pearson

Para comparar las dispersiones de dos o más conjuntos de valores no podemos confrontar simplemente las varianzas o las desviaciones estándar respectivas, puesto que estos coeficientes de dispersión vienen afectados por la escala de medida del respectivo valor. Es necesario, por tanto, eliminar esa influencia convirtiendo dichos valores en números sin unidades de medidas. Una medida que cumple perfectamente con este cometido es el llamado *coeficiente de variación de Pearson.*

Definición 1.3.17 *El* COEFICIENTE DE VARIACIÓN DE PEARSON *de un conjunto de datos, simbolizado por CV, es igual a la desviación estándar dividida entre la media, multiplicada por 100%. Es decir,*

$$CV = \left(\frac{\textit{desviación estándar de los datos}}{\textit{media aritmética de los datos}}\right) \cdot 100\%$$

Observemos que al dividir la desviación estándar por la media aritmética se elimina la influencia de la escala de medida, convirtiéndose así el coeficiente de variación en una medida útil para comparar conjuntos de datos con diferentes unidades de medida. El inconveniente de este coeficiente radica en que deja de ser utilizable cuando la media es igual a cero.

El siguiente ejemplo ilustra el cálculo del coeficiente de variación.

Ejemplo 1.3.18 *Los siguientes datos representan el promedio de millas por galón diario por cinco días para un determinado auto: 20, 25, 30, 15, 35. Encuentre el coeficiente de variación e interprete su respuesta.*

SOLUCIÓN:
La media y desviación estándar de millas por galón están dadas por $\overline{x} = 25$ y $s = 7,9$ respectivamente. Por tanto, el coeficiente de variación de estos datos es:

$$CV = \left(\frac{s}{\overline{x}}\right) \cdot 100\% = \left(\frac{7,9}{25}\right) \cdot 100\% = 31,6\%$$

Por consiguiente, el tamaño relativo de la "dispersión media alrededor de la media" con relación a la media es 31,6%. ◀

Copyright © 2014. Universidad del Norte. All rights reserved

Llinás Solano, H. (2014). Introducción a la estadística con aplicaciones en ciencias sociales: (ed.). Universidad del Norte. https://elibro.net/es/ereader/ucuauhtemoc/70062?page=19

Como medida relativa, el coeficiente de variación resulta especialmente útil cuando se compara la variabilidad de dos o más conjuntos de datos, que se expresan en diferentes unidades de medidas. Esto se muestra en el siguiente ejemplo.

Ejemplo 1.3.19 *El gerente de operaciones de un servicio de paquetería desea adquirir una nueva flota de autos. Cuando los paquetes se guardan con eficiencia en el interior de los autos (durante la preparación de las entregas), se deben considerar dos restricciones principales: el peso (en libras) y el volumen (en pies cúbicos) de cada paquete. Ahora, en una muestra de 200 paquetes, el peso promedio es 26 libras, con una desviación estándar de 3,9 libras. Además, el volumen promedio de cada paquete es 8,8 pies cúbicos, con una desviación estándar de 2,2 pies cúbicos. ¿Cómo se puede comparar la variación del peso y del volumen?*

SOLUCIÓN:
Como las unidades de medida difieren para las restricciones de peso y volumen, si el gerente de operaciones desea comparar las fluctuaciones en estas medidas, debe considerar la variabilidad relativa en ambos tipos de medidas. Para el peso, el coeficiente de variación es $CV = (3,9/26)100\% = 15\%$*; para el volumen, el coeficiente de variación es* $CV = (2,2/8,8)100\% = 25\%$*. Entonces, con relación a la media, el volumen de un paquete es mucho más variable que su peso porque el coeficiente de variación del peso es menor que el del volumen.* ◄

El coeficiente de variación es muy útil cuando se comparan dos o más conjuntos de datos que se miden con las mismas unidades, pero son tan diferentes que una comparación directa de las desviaciones estándar respectivas no ayuda mucho. Esto se ilustra en el siguiente ejemplo:

Ejemplo 1.3.20 *Un inversionista potencial piensa adquirir acciones en una de dos compañías A o B, listadas en la Bolsa de Valores de Nueva York. Si ninguna de las compañías ofrece dividendos a sus clientes y ambas tienen igual clasificación (según varios servicios de inversión) en términos de crecimiento potencial, el posible inversionista quizás considere la volatilidad (variabilidad) de ambas acciones para ayudar en la decisión de inversión. En los últimos meses, el precio promedio de las acciones en la compañía A fue de 50 dólares, con una desviación estándar de 10 dólares. Además, durante el mismo periodo, el precio promedio de las acciones en la compañía B fue de 12 dólares, con una desviación estándar de 4 dólares. ¿Cómo puede determinar el inversionista cuáles acciones son más variables?*

Copyright © 2014. Universidad del Norte. All rights reserved

Llinás Solano, H. (2014). Introducción a la estadística con aplicaciones en ciencias sociales: (ed.). Universidad del Norte. https://elibro.net/es/ereader/ucuauhtemoc/70062?page=19

SOLUCIÓN:
En términos de la desviación estándar, el precio de las acciones de A parece más volátil que el de las acciones de B. Sin embargo, como los precios promedio por acción de las dos compañías son tan diferentes, sería conveniente que el inversionista potencial considere la variabilidad en precio respecto al promedio a fin de examinar la volatilidad/estabilidad de ambas acciones. Para la compañía A, el coeficiente de variación es $CV = (10/50)100\% = 20\%$*; para la compañía B, el coeficiente de variación es* $CV = (4/12)100\% = 33,3\%$*. Entonces, en relación con la media, el precio de las acciones B es mucho más variable que el de las acciones A.* ◄

1.3.3 Medidas de colocación o de posición relativa

Una MEDIDA DE COLOCACIÓN O DE POSICIÓN RELATIVA para una distribución de frecuencias es aquel valor para el cual una porción específica de la distribución queda en o debajo de él. La mediana, los percentiles y cuartiles son ejemplos de medidas de posición relativa.

Percentiles y cuartiles

Definición 1.3.21 *El* p*-ÉSIMO (PUNTO) PERCENTIL es un valor tal que a lo más un* $p\%$ *de los datos tienen dicho o menos de ese valor.*

Los CUARTILES *son las medidas de posición relativa correspondiente a un conjunto ordenado de datos divididos en cuatro partes (iguales) y se definen así:*

- $Q_1 =$ *primer cuartil o* 25*-ésimo percentil.*
- $Q_2 =$ *segundo cuartil o* 50*-ésimo percentil o también mediana.*
- $Q_3 =$ *tercer cuartil o* 75*-ésimo percentil.*

Para calcular los cuartiles de un conjunto de n datos, es importante que tengamos en cuenta los siguientes pasos:

- Ordenemos los datos de manera ascendente.

Copyright © 2014. Universidad del Norte. All rights reserved

Llinás Solano, H. (2014). Introducción a la estadística con aplicaciones en ciencias sociales: (ed.). Universidad del Norte. https://elibro.net/es/ereader/ucuauhtemoc/70062?page=19

- Calculemos un índice (Q_k) a través de la fórmula $(Q_k) = nk/4$, siendo n la cantidad de datos y $k = 1, 2, 3$.
- Decidamos de acuerdo a uno de los dos casos:
  - Si el índice (Q_k) no es entero, lo aproximamos al entero siguiente. Este valor aproximado de (Q_k) indica la posición del k-ésimo cuartil.
  - Si (Q_k) es entero, el k-ésimo cuartil es el promedio de los valores de los datos ubicados en las posiciones (Q_k) y $(Q_k) + 1$.

Ejemplo 1.3.22 *Los siguientes datos representan los salarios (en millones de pesos) de 12 empleados en una empresa:*

$$\begin{array}{cccccc} 2,350 & 2,450 & 2,550 & 2,380 & 2,255 & 2,210 \\ 2,390 & 2,630 & 2,440 & 2,825 & 2,420 & 2,380 \end{array}$$

Calcule los cuartiles.

SOLUCIÓN:
Como primer paso fundamental debemos ordenar los datos de manera ascendente (preferiblemente con ayuda de un diagrama de tallo y hojas):

$$\begin{array}{cccccc} 2,210 & 2,255 & 2,350 & 2,380 & 2,380 & 2,390 \\ 2,420 & 2,440 & 2,450 & 2,550 & 2,630 & 2,825 \end{array}$$

Para determinar el primer cuartil, calculemos el índice correspodiente con $k = 1$ y $n = 12$. Al reemplazar obtenemos que $(Q_1) = 3$ (que es un número entero). Es decir, el primer cuartil es el promedio de los datos tercero (2,350) y cuarto (2,380), o sea, 2,365.

En conclusión, podemos decir que el 25% de los empleados tienen un salario menor o igual que $2.365.000. Calculando los cuartiles dos y tres como en el caso anterior, podemos verificar que

$$Q_2 = \frac{2,390 + 2,420}{2} = 2,405 \qquad y \qquad Q_3 = \frac{2,450 + 2,550}{2} = 2,500$$

Como tarea se deja al lector la interpretación de estos dos cuartiles. ◄

Comentarios adicionales

Se presentan estudios informales de la ética implícita en la selección entre promedios y otras cuestiones éticas de la estadística en general en [12].

Copyright © 2014. Universidad del Norte. All rights reserved

Llinás Solano, H. (2014). Introducción a la estadística con aplicaciones en ciencias sociales: (ed.). Universidad del Norte. https://elibro.net/es/ereader/ucuauhtemoc/70062?page=19

✍ Ejercicios de la sección 1.3

17. Responda las siguientes preguntas. Justifique sus respuestas.

    (a) ¿Qué escala de medida se requiere para la mediana? ¿Y para la moda?

    (b) ¿En qué condiciones coinciden la media, la mediana y la moda de una muestra?

    (c) ¿En qué caso será demasiado grande la diferencia entre la media y la mediana?

18. Una cadena de grandes almacenes tiene diez establecimientos. Se analiza el volumen de ventas durante el período de Navidad y se comparan con las obtenidas en el mismo período del año anterior. Los porcentajes de incrementos de ventas en dólares de los diez establecimiento fueron:

    10,2 3,1 5,9 7,0 3,7 2,9 6,8 7,3 8,2 4,3

    Halle la media, la mediana, la varianza muestral y la desviación típica. Intente interpretar sus respuestas.

19. Los puntajes finales de 20 alumnos en un curso de Estadística son:

    50 55 61 60 71 73 53 54 67 67
    54 77 72 76 81 83 87 44 48 67

    ¿Qué proporción de estos puntajes cae

    (a) dentro de ± 1 desviación estándar de la media?

    (b) dentro de ± 2 desviaciones estándar de la media?

    (c) dentro de ± 3 desviaciones estándar de la media?

20. Utilize la tabla de frecuencias para datos no agrupados obtenida en el ejercicio 7 para calcular la media, la mediana, la moda, la varianza muestral, la desviación típica muestral, coeficiente de variación y el sesgo. Intente interpretar sus respuestas.

21. La tabla siguiente contiene los salarios (en miles de pesos) de 30 trabajadores:

Salario anual	550	600	700	800	3.000
Frecuencia	8	6	7	5	4

Copyright © 2014. Universidad del Norte. All rights reserved

Llinás Solano, H. (2014). Introducción a la estadística con aplicaciones en ciencias sociales: (ed.). Universidad del Norte. https://elibro.net/es/ereader/ucuauhtemoc/70062?page=19

(a) Determine la moda, la media, la mediana y el sesgo.

(b) ¿Cuál medida de tendencia usaría para determinar el valor central? Explique.

(c) ¿Cuál es el primer cuartil y el tercer cuartil?

22. La tabla siguiente da una muestra de los tiempos de recorrido (en minutos) de un camino de 2,5 millas para el carro de José y el de Mariela:

José	0,8	0,9	1,0	0,9	1,0	1,0	0,9	1,0
Mariela	1,1	0,9	1,4	1,3	1,3	1,3	1,0	0,9

(a) Encuentre el promedio de los tiempos de recorrido para cada uno de los carros.

(b) Calcule la varianza de los tiempos de recorrido para cada uno de los carros respectivamente.

(c) ¿Qué auto tuvo un desempeño más consistente, si la consistencia se mide con la varianza? ¿Será esto correcto? Explique.

(d) Encuentre el coeficiente de variación para cada carro y comente al respecto.

23. Millones de habitantes de un cierto país se levantan cada mañana y trabajan en sus propias casas. Se sugiere que el uso creciente de computadoras es una de las razones por las que las personas pueden trabajar en empresas caseras. A continuación vemos una muestra de datos sobre las edades de esas personas:

57	31	30	41	22	58	24	50	29	52
37	32	44	49	29	44	40	46	29	31

(a) Calcule la media y la moda.

(b) Suponga que se sabe que la mediana de edad de la población de todos los adultos es de 35.1 años. Use la mediana de la edad de los datos anteriores para comentar si los trabajadores en casa tienden a ser más jóvenes o más viejos que la población de todos los adultos.

(c) Calcule el primero y el tercer cuartil y el 42% percentil. Interprete sus resultados.

24. En una prueba de rendimiento y consumo de gasolina se probaron 13 autos, durante 400 millas, en condiciones de tránsito en ciudad y en el campo; de lo anterior se obtuvieron los siguientes datos en millas por galón:

Copyright © 2014. Universidad del Norte. All rights reserved

Llinás Solano, H. (2014). Introducción a la estadística con aplicaciones en ciencias sociales: (ed.). Universidad del Norte. https://elibro.net/es/ereader/ucuauhtemoc/70062?page=19

Ciudad	14,4	13,2	15,3	16,8	16,2	16,7	15,9
	16,0	15,3	16,2	16,1	15,3	15,2	
Campo	18,3	18,6	19,2	17,4	19,4	20,6	17,2
	18,6	18,5	18,7	19,0	21,1	19,4	

Para llegar a una conclusión sobre la diferencia de rendimiento en la ciudad y en el campo, use el coeficiente de variación de ambos conjuntos de datos.

25. Una gran lechería vigila continuamente el nivel de contenido de grasa en su producto. El porcentaje de grasa no debe desviarse mucho del 1% de la leche, siendo aceptable una desviación estándar del 8%. Se obtuvo una muestra de 20 cartones de leche y se registró el porcentaje grasa en cada uno. Los resultados se anotan a continuación:

1,97	1,80	2,05	2,23	1,65	1,86	1,85	2,25	2,01	1,90
2,14	1,93	2,08	2,17	1,91	1,93	2,02	2,09	2,04	2,07

Calcule la media y la desviación estándar para la muestra de contenidos de grasa.

1.4 Diagrama de caja y bigotes

El DIAGRAMA DE CAJA Y BIGOTES, como el que se muestra en la figura 1.7, proporciona una representación gráfica de los datos mediante el resumen de cinco números.

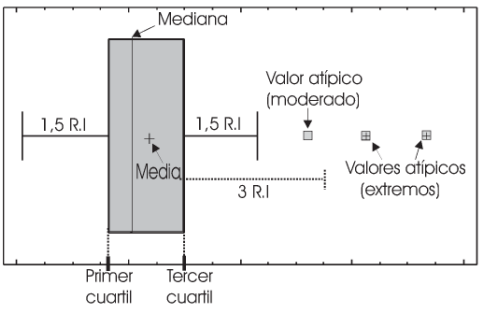


Figura 1.7: Diagrama de caja y bigotes

Copyright © 2014. Universidad del Norte. All rights reserved

Llinás Solano, H. (2014). Introducción a la estadística con aplicaciones en ciencias sociales: (ed.). Universidad del Norte. https://elibro.net/es/ereader/ucuauhtemoc/70062?page=19

Esta herramienta permite estudiar la simetría de los datos, detectar los valores atípicos y vislumbrar un ajuste de los datos a una distribución de frecuencias determinada.

El diagrama de caja y bigotes divide los datos en cuatro áreas de igual frecuencia, una caja central dividida en dos áreas por una línea vertical y otras dos áreas representadas por dos segmentos horizontales (bigotes) que parten del centro de cada lado de la caja. La caja central encierra el 50% de los datos.

En el interior de la caja central se acostumbra a representar la media con un signo más y se dibuja la mediana como una línea vertical en el interior de la caja (compárese con la figura 1.7).

Si esta línea está en el centro de la caja, no hay asimetría en los datos. Los lados verticales están situados en los cuartiles inferior y superior de los datos.

Partiendo del centro de cada lado vertical de la caja se dibujan los dos bigotes, uno hacia la izquierda y el otro hacia la derecha, teniendo en cuenta lo siguiente:

- El bigote de la izquierda tiene un extremo en el primer cuartil Q_1 y el otro extremo en el dato mayor o igual que $Q_1 - 1,5R.I.$ Aquí, R.I. simboliza el RANGO INTERCUARTIL, que es la diferencia entre el tercero y el primer cuartil.
- El bigote de la derecha tiene un extremo en el tercer cuartil Q_3 y el otro en el dato menor o igual que $Q_3 + 1,5R.I.$

Un valor atípico puede ser un elemento para el cual se haya anotado su valor en forma errónea. Si es así, puede corregirse antes de proseguir con el análisis.

También, un valor atípico puede ser uno que por error se incluyó en el conjunto de datos y, en estos casos, debe eliminarse.

Por último, puede ser tan sólo un elemento poco común que se haya anotado en forma correcta y que sí pertenece al conjunto de datos. En estos casos ese elemento debe mantenerse.

Copyright © 2014. Universidad del Norte. All rights reserved

Llinás Solano, H. (2014). Introducción a la estadística con aplicaciones en ciencias sociales: (ed.). Universidad del Norte. https://elibro.net/es/ereader/ucuauhtemoc/70062?page=19

Ejemplo 1.4.1 *Construya un diagrama de caja y bigotes para los datos del ejemplo* 1.3.22.

SOLUCIÓN:
Tenemos que el rango intercuartil es $R.I = 2,500 - 2,365 = 0,135$*, de donde se obtiene que la longitud de los bigotes es* $1,5R.I = 0,2025$*. Ahora,*

- *El bigote de la izquierda tiene un extremo en el primer cuartil* $Q_1 = 2,365$ *y el otro en el valor* $Q_1 - 1,5R.I = 2,1625$*.*
- *El bigote de la derecha tiene un extremo en el tercer cuartil* $Q_3 = 2,500$ *y el otro en el valor* $Q_3 + 1,5R.I = 2,7025$*.*

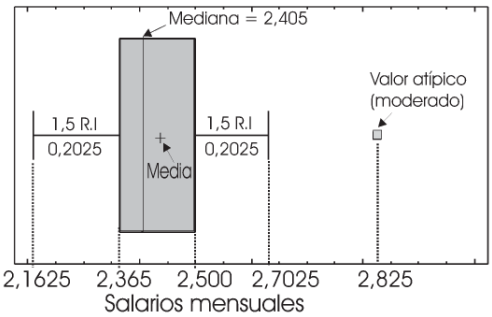


Figura 1.8: Diagrama de caja y bigotes para los datos del ejemplo 1.3.22

La figura 1.8 *es el diagrama de caja y bigotes pedido. En el diagrama podemos observar que hay un valor atípico (el valor 2,825) porque éste se encuentra por fuera de los bigotes. Debido a que* $Q_3 + 3R.I = 2,905$*, este valor atípico es moderado, porque 2,825 es menor que 2,905.*

Además, podemos afirmar que la distribución de frecuencias está sesgada a la derecha, porque el área del rectángulo a la izquierda de la mediana es menor que el del rectángulo a la derecha de la mediana.

Esto también se puede concluir al tener en cuenta que el valor de la media es mayor que el de la mediana. ◄

Copyright © 2014. Universidad del Norte. All rights reserved

Llinás Solano, H. (2014). Introducción a la estadística con aplicaciones en ciencias sociales: (ed.). Universidad del Norte. https://elibro.net/es/ereader/ucuauhtemoc/70062?page=19

Comentarios adicionales

Para obtener infor4mación acerca del análisis exploratorio de datos, véase por ejemplo, [10] y [29].

✍ Ejercicios de la sección 1.4

26. Un fabricante de baterías para linternas tomó una muestra de 13 baterías de un día de producción y las usó hasta que se agotaron. Las horas que funcionaron hasta fallar son:

    166 342 426 492 562 298 264 631 451 1.049 317 545 512

    Construya el diagrama de caja y bigotes, determine en cada caso si hay valores atípicos y haga un estudio de la simetría.

27. Los siguientes datos representan los rendimientos porcentuales anuales en cuentas de mercado de dinero de una muestra de 15 bancos comerciales en el área metropolitana de una ciudad a una determinada fecha:

Nombre del banco	Rendimiento	Nombre del banco	Rendimiento
Banco su cuenta	3,10	Banco el País	2,28
The Bank	2,63	Banco la Clave	3,01
Mein Bank	2,79	Banco del Norte	2,53
Your Bank	3,25	Banco del Sur	2,00
El Banco del pueblo	1,90	Banco Nacional	3,05
Aero Bank	2,79	Nuestro Banco	2,02
Union Bank	2,90	Banco el dinero	3,05
Bank del cliente	2,73		

    Construya el diagrama de caja y bigotes, determine en cada caso si hay valores atípicos y describa la forma.

1.5 Regresión lineal simple

En los análisis estadísticos, algunas veces es necesario estudiar la correspondencia de dos variables cuantitativas.

Copyright © 2014. Universidad del Norte. All rights reserved

Llinás Solano, H. (2014). Introducción a la estadística con aplicaciones en ciencias sociales: (ed.). Universidad del Norte. https://elibro.net/es/ereader/ucuauhtemoc/70062?page=19

Por ejemplo, el número de bebidas alcohólicas cosumidas, que denotaremos x, y la concentración de alcohol en la sangre, que denotaremos y, en sujetos con pesos corporales semejantes.

Para determinar si existe una relación lineal entre dos variables como x y y se construyen gráficos (diagrama de dispersión), se mide la fuerza de la relación lineal entre las variables (análisis de correlación) y se describen relaciones lineales (anális de regresión).

En toda la sección se tratarán unicamente relaciones lineales (línea recta).

1.5.1 Diagramas de dispersión

Las variables x y y pueden verse como una colección de pares ordenados (x, y), donde x afecta a y. Los diagramas de dispersión son planos cartesianos en los que se marcan los puntos (x, y) juntos, para visualizar la relación que existe entre las dos variables. Es recomendable registrar:

(a) Título del diagrama.

(b) Número de pares de datos.

(c) Título y unidades de cada eje.

Ejemplo 1.5.1 *El número de bebidas alcohólicas consumidas y la concentración de alcohol en la sangre para una muestra de 6 sujetos con pesos corporales semejantes, utilizado en un experimento son:*

Tabla 1.6: Datos para el ejemplo 1.5.1

Número de bebidas (x)	2	3	4	5	6	7
Concentración en la sangre (y)	0,05	0,09	0,11	0,13	0,17	0,20

Un diagrama de dispersión para las datos es como se muestra en la figura 1.9. *En ella se puede ver que la relación descrita por los puntos de datos está bien definida por una línea recta.*

Copyright © 2014. Universidad del Norte. All rights reserved

Llinás Solano, H. (2014). Introducción a la estadística con aplicaciones en ciencias sociales: (ed.). Universidad del Norte. https://elibro.net/es/ereader/ucuauhtemoc/70062?page=19

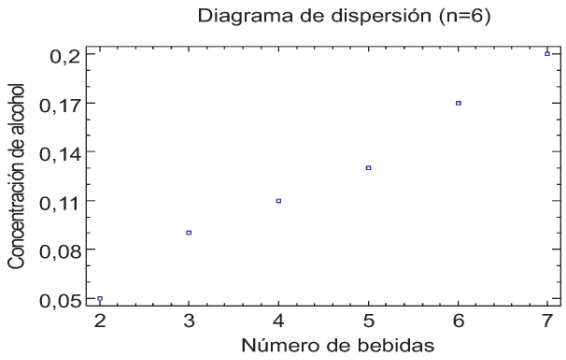


Figura 1.9: Diagrama de dispersión para los datos del ejemplo 1.5.1◀

1.5.2 Análisis de correlación

Para estudiar la relación entre x y y es importante hacer primero un diagrama de dispersión, sin embargo, para describir el grado hasta el cual una variable está linealmente relacionada con otra en términos cuantitativos, los estadísticos han desarrollado dos medidas: el coeficiente de correlación y el de determinación.

El coeficiente de correlación (R)

El coeficiente de correlación es la medida que describe qué tan bien una variable es explicada por otra y se calcula según la siguiente definición:

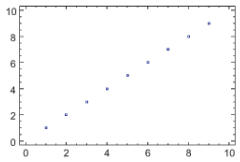
$$R = \frac{\sum xy \; - \; n\,\overline{x}\,\overline{y}}{(n-1)\,s_x\,s_y}$$

donde n es el número de pares de datos, s_x y s_y son las desviaciones estándar de X y Y respectivamente.

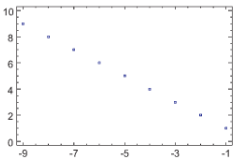
El coeficiente de correlación R se encuentra en el rango $-1 \leq R \leq 1$. La figura 1.10 muestra algunos diagramas de dispersión para diferentes valores de R.

Copyright © 2014. Universidad del Norte. All rights reserved

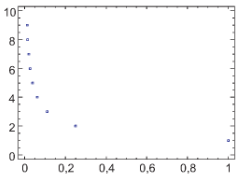
Llinás Solano, H. (2014). Introducción a la estadística con aplicaciones en ciencias sociales: (ed.). Universidad del Norte. https://elibro.net/es/ereader/ucuauhtemoc/70062?page=19



(a) $R = 1$



(b) $R = -1$



(c) $R = 0$

Figura 1.10: Gráficas de datos para diferentes valores de R

Diversas características del coeficiente de correlación

Ejemplo 1.5.2 *Calculemos el coeficiente de correlación para el ejemplo anterior de las bebidas alcohólicas. Los cálculos están organizados en la tabla* 1.7.

Tabla 1.7: Cálculo del coeficiente de correlación para los datos del ejemplo 1.5.1

x	y	xy
2	0,05	0,10
3	0,09	0,27
4	0,11	0,44
5	0,13	0,65
6	0,17	1,02
7	0,20	1,40
$\overline{x} = 4,500$	$\overline{y} = 0,125$	$\sum xy = 3,880$
$s_x = 1,870$	$s_y = 0,0543$	

De los resultados de la tabla anterior, obtenemos:

$$R = \frac{\sum xy \; - \; n\,\overline{x}\,\overline{y}}{(n-1)\,s_x\,s_y} = \frac{3,880 \; - \; (6)\,(4,500)\,(0,125)}{(6-1)\,(1,870)\,(0,0543)} = \frac{0,505}{0,5077} = 0,9946$$

De manera que hay una correlación lineal positiva fuerte entre las variables. ◄

Copyright © 2014. Universidad del Norte. All rights reserved

Llinás Solano, H. (2014). Introducción a la estadística con aplicaciones en ciencias sociales: (ed.). Universidad del Norte. https://elibro.net/es/ereader/ucuauhtemoc/70062?page=19